Pipeline para Predição de Churn e Segmentação de Clientes em Risco no Setor de Telecomunicações

Matheus Eduardo Laurindo do Rego
Especialização em Ciência de Dados — UTFPR
matheusrego@alunos.utfpr.edu.br
Banca do Projeto Integrador

Gemini Notebook

Contexto e problema

Em telecom, a lista de quem vai cancelar chega sem perfil

O cenário é o das operadoras de telecomunicações (banda larga): receita recorrente, canais digitais e planos sem fidelidade, em que trocar de empresa ficou barato para o cliente.

Cancelar (churn) custa caro: adquirir um assinante novo pesa bem mais do que reter quem já está na base.

A Ciência de Dados costuma responder com um classificador — uma lista de nomes em risco, sem dizer que tipo de cliente é cada um.

Sem perfil, a operação trata todo cliente em risco da mesma forma, quando cada tipo pode exigir uma ação diferente.



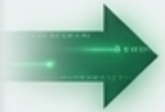
Hadden et al. (2007); Verbeke et al. (2012).

Gemini Notebook

Proposta

Um pipeline que devolve núcleos acionáveis a cada ciclo

1. Supervisionado (Classificar)



2. Não supervisionado (Agrupar)



3. MLOps (Repetir a cada ciclo)

Objetivo: a cada ciclo, devolver núcleos acionáveis — grupos de clientes em risco descritos em volume, fatura e receita exposta.

Como: um classificador estima o risco e corta no limiar; o K-Means agrupa só os sinalizados; MLOps faz o mesmo código rodar de novo na carteira do mês.

Metas definidas no início: F1 e acurácia de 80% na classe churn.

Base: IBM Telco Customer Churn, pública (7.043 clientes, 21 colunas) — contrato, acesso, serviços e fatura, como numa operadora.

Gemini Notebook

Estado da arte e diferencial

O mercado já prediz quem cancela; falta agrupar só o risco e republicar

- A literatura típica classifica churn e para no escore ou no ranking de lucro (Verbeke, 2012; Ahmad, 2019).
- Ullah (2019) classifica e depois agrupa, porém sobre quem já cancelou, e o resultado fica no caderno.
- Templates de nuvem e CRM entregam lista ou dashboard; quando segmentam, segmentam a carteira inteira.
- Este trabalho encadeia XGBoost e K-Means somente nos sinalizados e devolve núcleos acionáveis a cada ciclo do pipeline.

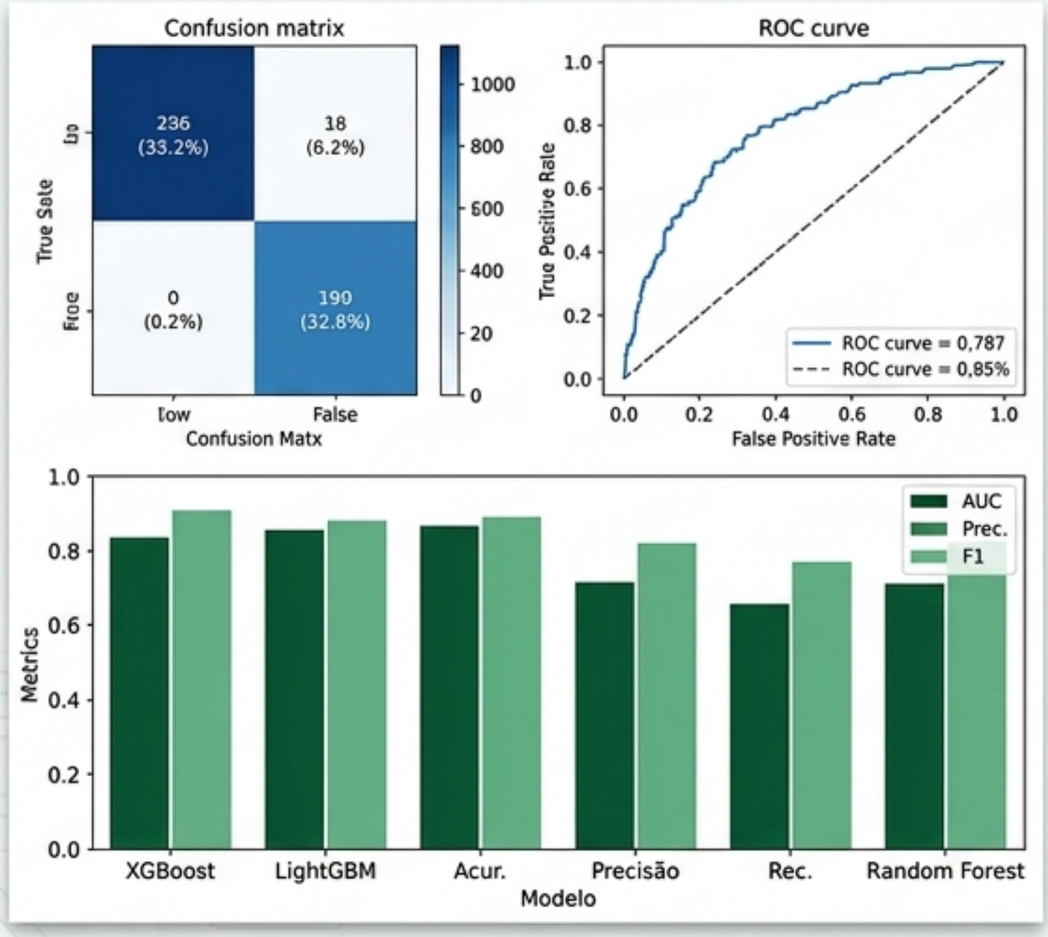
	Classifica	**Agrupa quem?**	**Volta a rodar?**
Literatura / CRM	sim	ninguém, ou a base toda	em geral não
Ullah (2019)	sim	quem já cancelou	não
Este trabalho	sim	só os sinalizados	sim (pipeline)

Verbeke et al. (2012); Ahmad et al. (2019); Ullah et al. (2019).

Gemini Notebook

Estudo piloto

Há sinal, mas o recorte mínimo não chega nas metas



Piloto no teste: regressão logística, 2 variáveis, limiar 0,5.

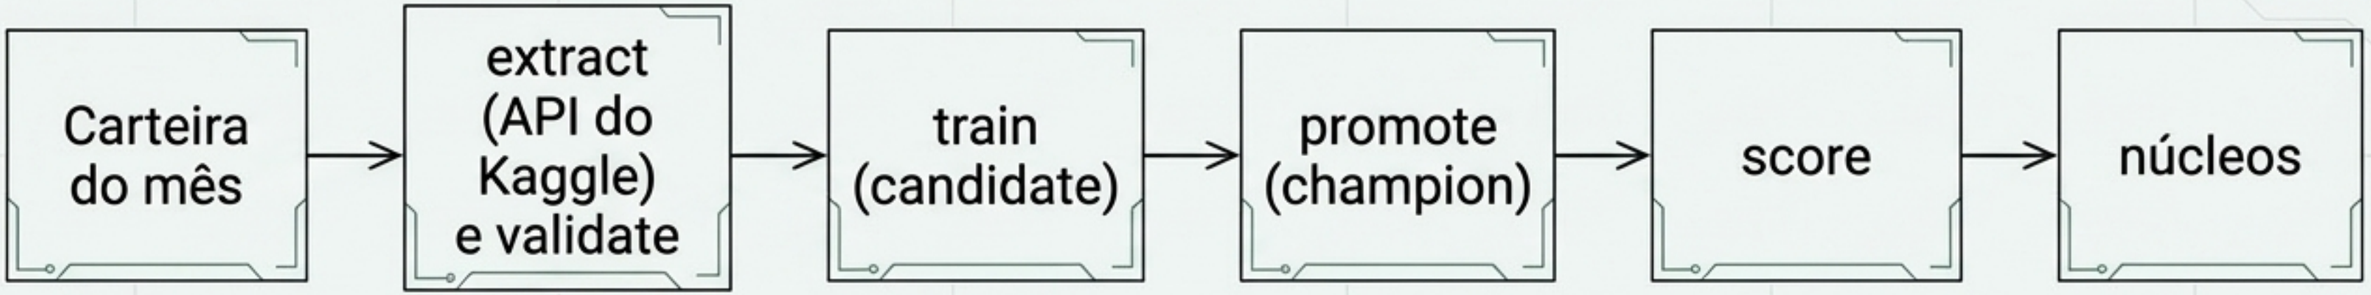
AUC	Acurácia	Precisão	F1
0,787	**75,5%**	**55,3%**	**46,2%**

- **Recorte mínimo** da mesma **IBM Telco:** 1.000 clientes, só tempo de casa e contrato, regressão logística e limiar 0,5.
- Resultado **abaixo das metas** de **80%**; 198 sinalizados em 2 grupos grosseiros (DSL vs fibra) e **R$ 11,6 mil/mês** expostos.
- O piloto levou ao **estudo completo**: todos os atributos, engenharia de features, limiar calibrado, ensembles e K = 3.

Gemini Notebook

Arquitetura

O mesmo código roda de novo a cada carteira

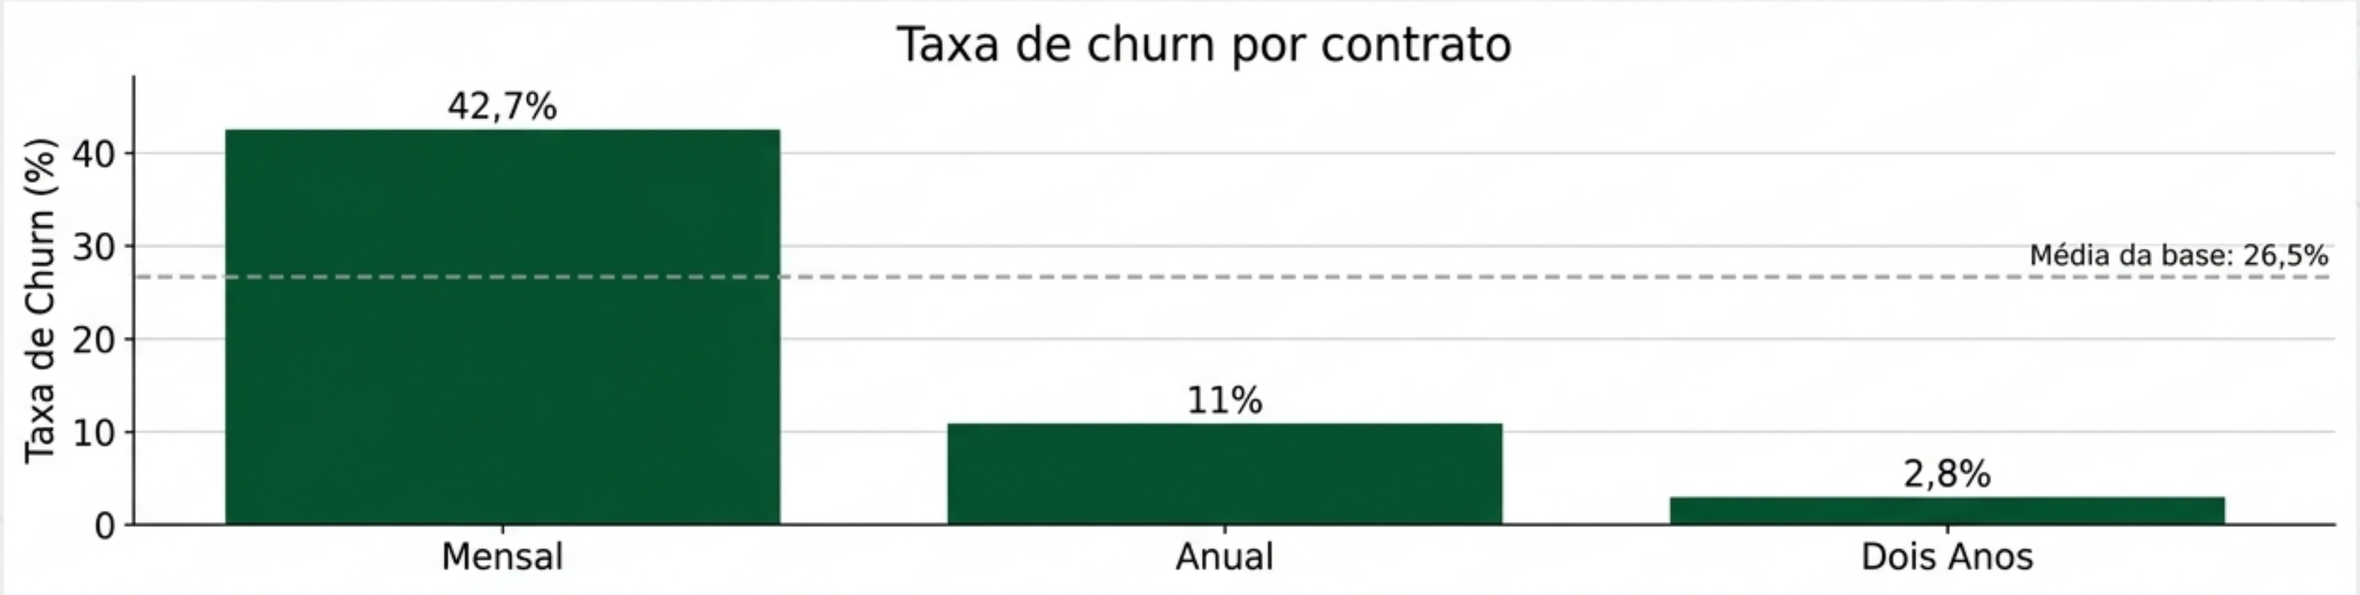


- Os notebooks definem a receita (Optuna, SHAP, K = 3); a API FastAPI dispara o lote no ciclo seguinte.
- Sem modelo champion no MLflow, o score não pontua — só roda modelo aprovado.
- Os números a seguir (1.556 clientes, R$ 123,4 mil) são a corrida de referência do laboratório; cada ciclo devolve o mesmo tipo de tabela.

Gemini Notebook

Base de dados e exploração

Na IBM Telco, o contrato mensal concentra o cancelamento



Taxa de churn por contrato. Linha tracejada = média da base (26,5%).

A IBM Telco tem 7.043 clientes e 21 colunas; 26,5% cancelaram.

No contrato mensal o churn é 42,7%; no de dois anos, 2,8%. Quem cancela também tem menos tempo de casa (18 vs 38 meses).

Como só essas duas variáveis não bastaram no piloto, o estudo completo derivou 47 atributos a partir das 21 colunas originais.

Gemini Notebook

Modelagem da classificação

O limiar pesa mais do que a escolha do algoritmo

$$S = 0{,}6 \cdot F(\beta = 0{,}5) + 0{,}4 \cdot \text{acurácia}$$

Foram comparados Random Forest, XGBoost e LightGBM (Optuna, 40 tentativas, 5 folds), com peso de classe e sem SMOTE.

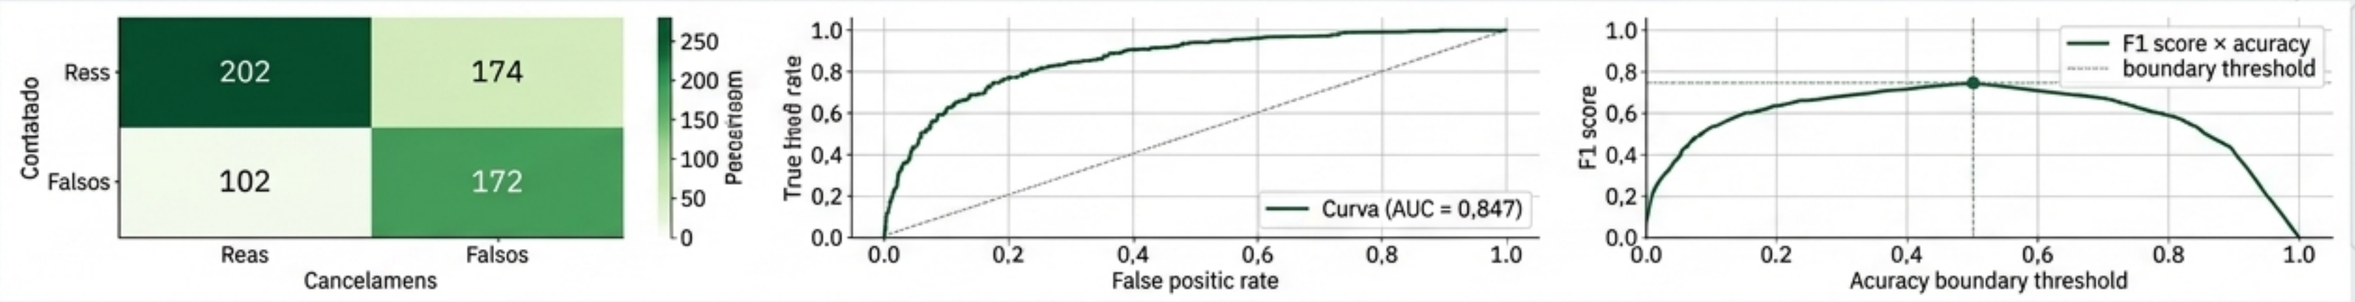
Como cada nome sinalizado vira contato, o objetivo privilegia precisão: $S = 0{,}6 \cdot F(\beta = 0{,}5) + 0{,}4 \cdot$ acurácia, com o limiar dentro da busca.

Os três empatam; o XGBoost vence no escore composto. Limiar calibrado: 0,795 (medir em 0,5 seria enganoso).

Gemini Notebook

Resultados da classificação

Dois em cada três contatados cancelariam de fato



Teste com 1.409 clientes: matriz, ROC e teto de F1 × acurácia.

AUC	Acurácia	Precisão	Recall	F1
0,847	**80,6%**	**66,4%**	**54,0%**	**59,6%**

Dos **304** clientes sinalizados no teste, **202 cancelaram** (102 alarmes falsos); dos **374** cancelamentos reais, **172** escaparam.

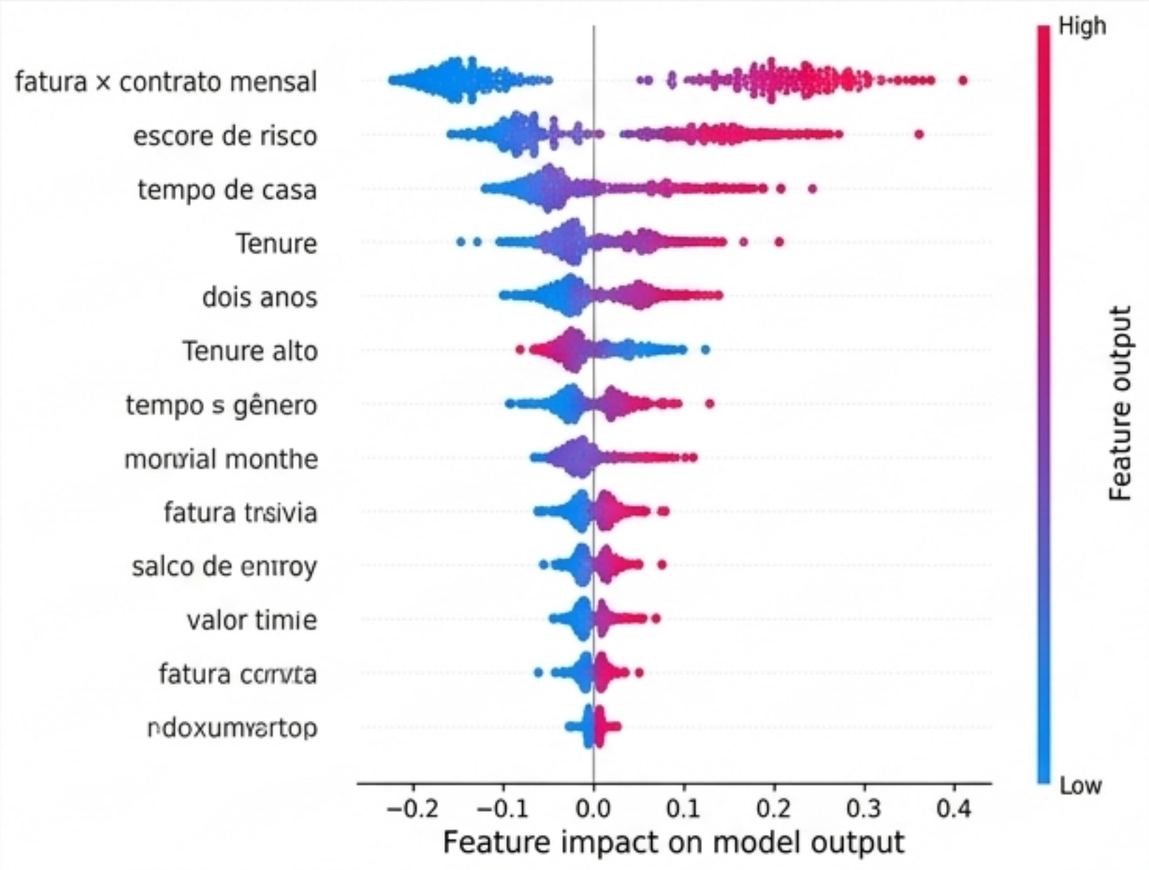
Precisão ≈ 2,5 vezes a taxa base (26,5%). Meta de acurácia atingida; a de F1 não — nenhum limiar passa de **63,7%** nesta base.

O **limite está nos dados** (sem consumo, atendimento ou qualidade), não na falta de um quarto algoritmo.

Gemini Notebook

Interpretabilidade

O modelo se apoia nas features derivadas, não em demografia



15 variáveis mais influentes. Azul = valor baixo; vermelho = alto.

- As duas variáveis mais importantes foram criadas no estudo: fatura × contrato mensal e o escore de risco. Em terceiro vem o tempo de casa.
- Tenure alto e contrato de dois anos reduzem o risco estimado; gênero não entra no topo.
- O SHAP explica o modelo, não a causa — não se afirma que baixar a fatura reduz o cancelamento.

Gemini Notebook

Núcleos acionáveis

A saída de cada ciclo são três grupos, não uma lista única

Núcleo 0 — novos em DSL

241 clientes (15,5%)

2,7 meses · R$ 42,47/mês

65,6% cancelaram

Núcleo 1 — veteranos em fibra

427 clientes (27,4%)

26,7 meses · R$ 94,54/mês

66,5% cancelaram

Núcleo 2 — novos em fibra

888 clientes (57,1%)

4,8 meses · R$ 81,93/mês

72,1% cancelaram

1.556 sinalizados (22,1% da base), limiar 0,795, K = 3, silhueta 0,283. O classificador montou a lista; o K-Means montou os núcleos que a empresa lê.

Gemini Notebook

Impacto financeiro

Volume de clientes não é volume de receita



Fatia de cada núcleo nos R$ 123,4 mil mensais expostos.

- Os 1.556 sinalizados expõem R$ 123,4 mil por mês (cerca de R$ 1,48 milhão no ano) — exposição bruta, não perda esperada.
- O núcleo 0 tem 15,5% dos nomes e só 8,3% do dinheiro; o núcleo 2 tem 57,1% dos nomes e 59,0% da receita.
- Uma campanha única para os 1.556 misturaria quem paga R$ 42 com quem paga R$ 95 — por isso os núcleos existem.

Gemini Notebook

Análise exemplar de campanha

Um caminho possível por núcleo — a ação cabe à operação

Núcleo 0

Núcleo 0 (DSL novo, fatura baixa): hipótese de atrito de adoção — integração por canal barato e convite ao contrato anual.

Núcleo 1

Núcleo 1 (fibra veterana, fatura alta, sem suporte): contato humano e um período de suporte incluso, porque o ticket paga o esforço.

Núcleo 2

Núcleo 2 (fibra recente, 59% da receita, maior risco): prioridade em qualidade de sinal e oferta de permanência.

Análise exemplar. O Projeto Integrador devolve os núcleos; canal, oferta e KPI ficam com a operação.

Gemini Notebook

Conclusão e próximos passos

Os núcleos separam volume de valor; o próximo ganho está nos dados

- Encadear classificação e agrupamento agrega decisão: volume e receita não caminham juntos entre os núcleos.
- Limiar calibrado e engenharia de features pesaram mais do que a escolha do algoritmo — os três ensembles empataram.
- O teto de F1 (63,7%) está na base: avançar exige novos dados, não um modelo mais complexo.

Limitações: sem consumo, atendimento ou qualidade; sem dimensão temporal; silhueta 0,283 (grupos úteis, não naturais); SHAP não é causa.

Próximos passos: enriquecer a base; trocar exposição bruta por perda esperada; testar ações com grupo de controle; alarme de deriva dos núcleos.

Gemini Notebook

Perguntas e respostas

Cinco perguntas que resumem o projeto

P. Qual o problema no cenário de telecom?
R. A lista de risco chega sem perfil, e todo cliente recebe a mesma ação.

P. O que o projeto entrega?
R. Um pipeline que classifica, agrupa só os sinalizados e republica os núcleos.

P. Que base foi usada?
R. A pública IBM Telco Customer Churn: 7.043 clientes, estrutura de operadora.

P. Qual o resultado da corrida de referência?
R. AUC 0,847, precisão 66,4%; 1.556 sinalizados em 3 núcleos, R$123,4 mil/mês.

P. A campanha é a entrega?
R. Não: é análise exemplar. A entrega é o pipeline que republica os núcleos.

Gemini Notebook

Agradecimento

Obrigado.

Matheus Eduardo Laurindo do Rego

Especialização em Ciência de Dados — UTFPR

matheusrego@alunos.utfpr.edu.br

github.com/matheuseduardolr/projeto_integrador

Gemini Notebook